

# Lectura 7: A technical overview of Azure Cosmos DB

---

## Bases de datos II

---

Estudiante: Fabricio Monge Brenes Carnet: 2023108707

---

### Instrucciones

Tiempo estimado de lectura: 20 minutos

¿Cómo funciona el particionamiento horizontal en ComosDB?

¿Comente el modelo de consistencia de CosmosDB?

¿Comente como los objetivos de diseño de CosmosDB afectan la creación de aplicaciones?

---

### Respuestas

1.

Todos los datos dentro de un contenedor de azure Cosmo DB se particiona horizontalmente y se gestiona de forma transparente mediante particiones de recursos. Una particion de g¿reucrsos es un contenedor de datos consistente y de alta disponibilidad, particionados por una clave de partición definida por el cliente y constituye la unidad fundamental de escalabilidad y distribución. Además, El sistema se diseñó para que el cliente pueda escalar de forma elastica el rendimiento de la base, se puede aprovisionar de rendimiento mediante Unidades de Solicitud. Finalmente, Los contenedores de Cosmo DB se distribuyen globalmente y se distribuyen en dos dimensiones: Horizontalmente o distribución local, y las particiones de recursos se replican entre regiones geográficas (distribución global).

2.

Azure Cosmos DB permite a los desarrolladores elegir entre cinco modelos de consistencia bien definidos a lo largo del espectro de consistencia: strong, bounded staleness, session, consistent prefix y eventual, a diferencia de otros modelos de bases que ofrecen fuerte o eventual solamente. Así mismo, los desarrolladores pueden configurar el nivel de consistencia predeterminado en su cuenta de base de datos y, posteriormente, anular la consistencia en una solicitud de lectura específica. Además, para reportar cualquier violación de los SLAs de consistencia, Cosmos DB emplea un verificador de linealizabilidad que opera continuamente sobre la telemetría del servicio.

3.

Los objetivos de diseño de Azure Cosmos DB, definidos desde sus inicios en 2010, buscan cubrir las limitaciones fundamentales de los desarrolladores que construyen aplicaciones a escala de internet. Estos objetivos afectan a la creación de aplicaciones de la siguiente manera:

- Escalado elástico global de rendimiento y almacenamiento: El sistema debe entregar el 99% del rendimiento configurado en 5 segundos desde la solicitud de escalado. Esto permite a las aplicaciones

adaptarse a demandas fluctuantes sin intervención manual compleja

- Aplicaciones críticas con baja latencia garantizada: Se debe ofrecer latencias de lectura y escritura predecibles y garantizadas de extremo a extremo al percentil 99, lo cual es esencial para aplicaciones que requieren alta capacidad de respuesta
- Sistema "siempre activo": Se garantiza una disponibilidad del 99.99% independientemente del número de regiones asociadas. Además, se permite a los clientes simular fallos regionales para validar las propiedades de disponibilidad de sus aplicaciones
- Modelo de programación intuitivo para la consistencia: Se busca que los desarrolladores puedan escribir aplicaciones globalmente distribuidas correctas. El artículo advierte que, aunque la consistencia fuerte tiene un costo, escribir aplicaciones grandes contra una base de datos "eventualmente consistente" produce código frágil y difícil de razonar, propenso a errores de corrección
- Sin gestión de esquemas ni índices: Esto libera al desarrollador de la carga de gestionar el esquema y los índices de la base de datos, una tarea que puede llegar a ser complicada en aplicaciones globalmente distribuidas
- SLAs financieramente respaldados
- Soporte nativo de múltiples modelos de datos y APIs
- Bajo costo operativo

En conjunto, estos objetivos permiten que las aplicaciones se construyan asumiendo que la base de datos maneja la distribución global, la escalabilidad, la disponibilidad y la consistencia de forma transparente, dejando al desarrollador enfocarse en la lógica de negocio y en la elección del nivel de consistencia adecuado para cada caso de uso.